



**DETECCIÓN AUTOMÁTICA DE ACORDES DE GUITARRA ACÚSTICA
A PARTIR DE SEÑALES DE AUDIO MEDIANTE APRENDIZAJE
AUTOMÁTICO**

**SAMUEL ALJURE BERNAL
JUAN DAVID CÓRDOBA AGUIRRE
JUAN ESTEBAN BUITRAGO CHÁVEZ**

**UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS
FACULTAD DE INGENIERÍA
BOGOTÁ, COLOMBIA
2026**



**Detección automática de acordes de guitarra acústica a partir de señales de audio
mediante aprendizaje automático**

**Samuel Aljure Bernal
Juan David Córdoba Aguirre
Juan Esteban Buitrago Chávez**

Trabajo de grado para optar al título de:
Ingeniería de Sistemas

Director:
Helbert Eduardo Espitia Cuchango, Ph.D.
Profesor Titular - Facultad de Ingeniería

Universidad Distrital Francisco José de Caldas
Facultad de Ingeniería
Proyecto Curricular de Ingeniería de Sistemas
Bogotá, Colombia
2026

Índice general

I	Descripcion del proyecto	1
1.	Descripción del proyecto	2
1.1.	Resumen	2
1.2.	Justificación	2
1.3.	Introducción	3
1.3.1.	Descripción del problema	3
2.	Objetivos	4
2.1.	Objetivos	4
2.1.1.	Objetivo general	4
2.1.2.	Objetivos específicos	4
II	Marco teorico	6
3.	Marco de Referencia	7
3.1.	Estado del arte	7
3.2.	Marco Teórico	9
3.2.1.	Señales de audio digital	9
3.2.2.	Análisis espectral	10

3.2.3. Representación musical: notas y acordes	10
3.2.4. Extracción de características	11
3.2.5. Aprendizaje automático aplicado al audio	12
 III Desarrollo	 13
 4. Diseño e implementación	 14
4.1. Alcance	14
4.1.1. Objetivo general del alcance	14
4.1.2. Delimitación funcional	14
4.2. Limitaciones	15
4.3. Plan de trabajo	16
4.3.1. Revisión documental	16
4.3.2. Implementación del modelo	16
4.3.3. Preprocesamiento de datos	16
4.3.4. Entrenamiento del modelo	16
4.3.5. Comparación de modelos	16
4.3.6. Pruebas	17
4.4. Cronograma	18

Parte I

Descripcion del proyecto

Capítulo 1

Descripción del proyecto

1.1. Resumen

La transcripción automática de música (Automatic Music Transcription, AMT) es un área de investigación dentro del campo de Music Information Retrieval (MIR) cuyo objetivo consiste en transformar señales de audio musical en representaciones simbólicas como notas, acordes o partituras. Este problema resulta especialmente complejo en instrumentos polifónicos como la guitarra acústica, donde múltiples notas se producen simultáneamente generando espectros armónicos superpuestos.

En este trabajo se presenta un enfoque para la detección e identificación automática de acordes de guitarra acústica a partir de grabaciones de audio. La metodología propuesta se basa en el procesamiento espectral de la señal y en el uso de modelos de aprendizaje automático para reconocer patrones armónicos asociados a distintos acordes musicales.

Este estudio busca contribuir al desarrollo de herramientas computacionales que faciliten el análisis automático de interpretaciones musicales y la generación de representaciones simbólicas a partir de señales de audio [1].

1.2. Justificación

La transcripción automática de la música presenta un desafío al momento de procesar las señales digitales, de igual forma constituye un problema que toma gran relevancia al momento de recuperar información musical (MIR), esta tiene un gran potencial para transformar la manera en que se analiza, se interpreta y se accede al contenido musical [2]. A pesar de los avances recientes en los ámbitos de machine learning, los sistemas actuales no tienen la capacidad máxima de precisión y flexibilidad al comparar con un músico profesional, ya que estos tienen la capacidad de entender información polifónica mucho más amplia, en estos escenarios polifónicos complejos se convergen múltiples voces, sonidos y narrativas sonoras que son complejas para una máquina de entender de manera simultánea [1].

El desarrollo de aplicaciones que permitan la extracción de información como acordes, estructuras musicales, datos de frecuencia y demás, puede llegar a ser una herramienta clave para un aprendizaje musical, que puede acompañar al interesado y así darle un respectivo uso educativo. La base para el desarrollo de una aplicación parte de una transcripción musical, donde permite la conversión de información auditiva en representaciones simbólicas, esto constituye la base de un estudio, una interpretación y una aplicación en respectivos contextos [2]. En este sentido, automatizar este proceso contribuye en una reducción del tiempo y de dificultad a intérpretes cuya tarea sea transcribir de forma manual y presentarle más información que no sea solo en formato de partitura.

1.3. Introducción

1.3.1. Descripción del problema

En los últimos años, la inteligencia artificial ha avanzado hasta resolver tareas que hace una década parecían prohibitivas. La detección de objetos en tiempo real, el análisis de imágenes médicas y la traducción automática son problemas que hoy tienen soluciones competitivas, a veces superiores al desempeño humano en condiciones controladas. Sin embargo, no todo el territorio está cubierto: la música resiste, y lo hace por razones que no se resuelven añadiendo más datos o más capas, como la percepción, el contexto y las decisiones interpretativas, que no caben fácilmente en una función de pérdida.

La transcripción musical automática (AMT) sigue siendo un reto, ya que va más allá del procesamiento y análisis de audio para su posterior transcripción. En el caso de los instrumentos polifónicos, se debe tener en cuenta la superposición espectral que se produce al formar acordes, lo que conlleva consideraciones más detalladas, como el material de las cuerdas. En la guitarra acústica con cuerdas de nailon, por ejemplo, se presenta una menor inarmonicidad y un *decay* más pronunciado que en las cuerdas metálicas, lo que altera la distribución de armónicos en el espectrograma.

Además de las condiciones físicas del instrumento, se deben tener en cuenta las distintas técnicas de ejecución. Por ejemplo, un acorde Am7 puede sonar perceptiblemente distinto según se toque con los dedos o con púa, en distintas posiciones del mástil, con vibrato, ejecutando con *muting* parcial o cambios de dinámica. De igual forma, el trasfondo de la teoría musical, como la enarmonía, introducen otra capa de complejidad. Notas como Do# y Reb comparten frecuencia fundamental, pero representan acordes distintos según el contexto armónico, una distinción que el espectrograma por sí solo no puede resolver y que requiere contexto adicional o intervención humana para mejorar su precisión.

Capítulo 2

Objetivos

2.1. Objetivos

En esta sección se plantean los objetivos generales y específicos que guiarán el desarrollo de este trabajo de investigación.

2.1.1. Objetivo general

Desarrollar un sistema automático que, a partir de una grabación de audio de guitarra acústica, identifique el acorde que se está ejecutando con una precisión exacta mínima del 85 % y genere su representación simbólica en cifrado americano.

2.1.2. Objetivos específicos

- Extraer y comparar cuatro tipos de características acústicas (transformada de Fourier de tiempo corto, CQT, chromagram y energía de armónicos) para determinar la representación más adecuada para la detección de acordes.
- Implementar y entrenar tres arquitecturas de aprendizaje automático (CNN 2-D, CNN + RNN, Transformer) y optimizar sus hiperparámetros mediante búsqueda bayesiana.
- Evaluar el desempeño de cada modelo mediante exact-match accuracy, top-3 accuracy y macro-F1, utilizando validación cruzada de 5-fold.
- Analizar la robustez del mejor modelo frente a variaciones de afinación, técnicas de ejecución y presencia de ruido de fondo, reportando la degradación del rendimiento por cada factor.
- Documentar el proceso completo y publicar los resultados en una revista de Music Information Retrieval, liberando el código fuente bajo licencia MIT en GitHub.

- Investigar y discutir las limitaciones del sistema propuesto, así como posibles mejoras y aplicaciones futuras en el ámbito de la transcripción musical automática y el análisis de audio.

Parte II

Marco teorico

Capítulo 3

Marco de Referencia

3.1. Estado del arte

La transcripción automática de música (Automatic Music Transcription, AMT) es una de las áreas más importantes dentro del campo de *Music Information Retrieval* (MIR). Básicamente, el objetivo de la transformación es convertir el sonido físico en un elemento que se pueda escribir, leer e interpretar, tal como una nota musical o una partitura en específico [3]. Parece algo sencillo de entender, sin embargo, es un problema bastante complejo, donde no se ha tocado fondo; esto puesto que una señal de audio puede contener múltiples sonidos ocurriendo al mismo tiempo, provocando que intentar identificar correctamente cada nota se torne muy problemático: cuándo empieza, cuándo termina y de dónde proviene.

Indagando en los principios de la transcripción automática de música, los enfoques principales que se usan para resolver este problema se basan en técnicas clásicas de procesamiento de señales. Estas técnicas suelen recurrir a las transformadas espectrales y a modelos probabilísticos para identificar eventos musicales a partir del espectrograma [4]. Este tipo de técnicas funcionan relativamente bien, pero únicamente cuando se trata con una sola nota a la vez, también conocidas como señales monofónicas. Sin embargo, las situaciones más problemáticas se presentan cuando varias notas suenan simultáneamente, siendo estas notas polifónicas, como ocurre en los acordes, debido a la superposición de sus componentes frecuenciales en cada caso.

Respecto al problema de la superposición, los investigadores comenzaron a explorar representaciones más adecuadas para la música. Una de las más importantes es la *Constant-Q Transform* (CQT), que permite representar las frecuencias de una forma más cercana a cómo las percibe el oído humano, presentándose como una herramienta clave para el tratamiento de los acordes [5]. Gracias a esto, los sistemas más actualizados pueden reconocer mejor los patrones armónicos, las notas y frecuencias de una forma más precisa, fundamental para el tema de identificar acordes y estructuras musicales más complejas.

Posterior al CQT, apareció un fenómeno mundial que definiría el futuro de la era tecnológica: el aprendizaje automático. La incorporación del Machine Learning marcó un punto de inflexión en el estudio futuro de este campo. En lugar de depender únicamente de reglas matemáticas,

los modelos comenzaron a aprender directamente a partir de los datos que eran retroalimentados constantemente. Como ejemplo, se sabe que las redes neuronales convolucionales pueden identificar patrones característicos en las señales de audio que corresponden a eventos musicales específicos, lo que facilita en gran medida el trabajo del tema [6]. De igual forma, otros trabajos han mostrado mejoras en la precisión de la transcripción al analizar características acústicas, esto llevado a cabo mediante algoritmos de aprendizaje automático que monitorean y hacen uso de datos reales [7].

Recientemente, los avances en aprendizaje profundo han permitido desarrollar modelos más sofisticados capaces de abordar la transcripción musical de forma más íntegra con la capacidad humana de interpretación. Un ejemplo de esto es el enfoque *end-to-end*, donde el sistema recibe directamente el audio y produce la transcripción sin necesidad de etapas intermedias complejas que alarguen y compliquen el proceso [8]. Este tipo de modelos es especialmente útil en instrumentos como la guitarra, el caso de estudio, donde los acordes están formados por varias notas que se superponen en el espectro de frecuencias y son de necesario abordaje y estudio.

Además de lo anterior, algunos estudios han propuesto mejorar estos sistemas incorporando información adicional que nutra mejor los datos. Por ejemplo, el uso de estadísticas musicales que permitan hacer transcripciones más coherentes desde el punto de vista estructural y analítico de un sistema avanzado [9]. De igual forma, se han desarrollado soluciones específicas para distintos tipos de notación o instrumentos de gran complejidad, como tablaturas de órgano o en instrumentos tradicionales, lo que demuestra la diversidad que hay y los enfoques dentro del área que pueden ser abordados [10, 11].

En otra línea de trabajo de igual relevancia, está la adaptación de los modelos a contextos musicales específicos. Técnicas como el *fine-tuning* permiten ajustar modelos previamente entrenados para que reconozcan mejor ciertos estilos o características particulares de la música [12]. También se ha explorado el uso de información contextual para mejorar la interpretación de las señales según sea el contexto, lo cual es clave en un dominio donde el significado musical depende en gran medida de un entorno en el que se desarrolla [13].

Los datos y revisiones recientes coinciden en que los mejores resultados se logran combinando buenas representaciones de una señal, modelos de aprendizaje profundo y grandes conjuntos de datos etiquetados, siempre y cuando se manejen los datos con mucho detalle y rigurosidad [14]. En esta línea de trabajo, varios proyectos actuales utilizan directamente espectrogramas como entrada a modelos de redes neuronales, logrando avances significativos en la detección de notas, acordes y progresiones armónicas en mucho menos tiempo y con una efectividad enorme [15, 16].

En un contexto más general, la evolución de este entorno muestra un claro paso desde métodos tradicionales hacia modelos basados en aprendizaje profundo. Este representa un cambio que ha permitido mejorar considerablemente el rendimiento de los sistemas de transcripción automática; a pesar de todos los avances, todavía existen desafíos importantes, especialmente en escenarios polifónicos y en la generalización a distintos instrumentos que pueden representar una dificultad mucho mayor a uno corriente y que, desde luego, son aspectos que se quiere llegar a dominar.

Finalmente, se han desarrollado otros estudios que han abordado problemas relacionados, como la alineación entre audio y partituras, donde se busca, mediante la utilización de redes neuronales recurrentes, la mejora significativa de la precisión de la transcripción de la música

[17]. También se han realizado avances respecto a los sistemas automáticos de generación de partituras y modelos híbridos que combinan análisis espectral con aprendizaje automático, que ya dan un paso adelante en la comprensión total [18, 19]. Desde una perspectiva más amplia, algunos trabajos destacan la importancia de integrar conocimientos de teoría musical con enfoques computacionales y son el eje principal en el desarrollo de sistemas que comprendan la música [20]; y, por otra parte, están las revisiones del área que identifican como principales retos la complejidad de la polifonía y la adaptación de los modelos a diferentes contextos musicales, ampliando por mucho la comprensión del tema [21].

3.2. Marco Teórico

Dentro de la fundamentación teórica para el desarrollo de este proyecto, se encuentran diversas técnicas para generar espectrogramas de audio, entre las más relevantes están las transformadas de fourier, que junto a una aplicación sólida de la teoría musical sobre el desarrollo técnico, asegura que el aprendizaje sea mucho más sólido y coherente. A continuación se profundizará sobre cada apartado.

3.2.1. Señales de audio digital

Una señal de audio digital es representada por una onda sonora que viaja a través del espacio y es percibida por las personas o seres con capacidad auditiva, esta es percibida en un rango de frecuencia en específico (20hz y 20khz), son de naturaleza analógica, por lo que estarán continuamente sobre un tiempo y amplitud. El audio digital se compone de información almacenada, si se explora cualquier base de datos de audio, se encontraran archivos digitales con fragmentos de sonido que pueden contener narraciones o música. Estos existen en diferentes formatos de archivo como .wav (Waveform Audio File), .flac (Free Lossless Audio Codec) y .mp3 (MPEG-1 Audio Layer 3). Estos formatos difieren principalmente en como comprimen la representación digital de la señal de audio.

Ya entrado en detalle, los sonidos provenientes del mundo real varían continuamente, y estos, al momento de la grabación digital, son solo una aproximación de la gama completa presente en la vida real. No obstante, los avances alcanzados en las tecnologías de grabación amplían continuamente el espectro y la precisión de lo que puede grabarse digitalmente.

Cuando se realiza una grabación digital desde una fuente analógica, como sucede en un concierto en directo o un grupo de músicos que se encuentran en un estudio de grabación, el sonido se muestra en intervalos periódicos. La amplitud del sonido se graba como un número, lo que crea un registro digital de la fuente de audio analógica con una serie de números discretos.

Para determinar la cantidad de sonido analógico original que se captura con la grabación digital, se depende principalmente de la velocidad de muestreo y de la profundidad de los bits (número de muestras que se toman por segundo y cantidad de información que contiene cada muestra).

AL obtener la grabación de audio digital, esta puede ser almacenada en diversos formatos,

incluyendo los anteriormente mencionados, cada uno de los cuales tiene un modo distinto de equilibrar la calidad del sonido con el tamaño del archivo digital que se está creando. Sin embargo el tamaño del reproductor de música afecta directamente a la recepción de la calidad del audio.

3.2.2. Análisis espectral

El análisis espectral es fundamental para entender la profundidad de un audio como señal, esta permite la distribución de energía de una señal en función de la frecuencia. Para este caso el audio consiste en el análisis al descomponer una señal sonora compleja en sus componentes frecuenciales, así permitiendo la identificación de las frecuencias presentes y su amplitud

Profundizando en el contexto matemático, el análisis espectral se basa en la Transformada de Fourier, por la cual se permite representar una señal en el dominio del tiempo como si fuera una suma de ondas sinusoidales con distintas frecuencias. En lo que es procesamiento digital de señales, esta se utiliza comúnmente con la Transformada Rápida de Fourier (FFT), que permite como tal una implementación eficiente de este cálculo de frecuencias.

En este contexto de ondas, el espectrograma pasa a ser en una herramienta clave, esta ya pasa a permitir visualizar simultáneamente la evolución temporal del fenómeno, las frecuencias presentes en cada instante y su intensidad. Dentro de un espectrograma, comúnmente, el eje horizontal representa el tiempo, el eje vertical la frecuencia, y la intensidad de cada componente se representa mediante colores o niveles de grises.

Como tal, el análisis espectral es precisamente relevante ya en aplicaciones musicales, ya que lo que son las notas y los acordes están directamente relacionados con una serie de combinaciones específicas de frecuencias. Por lo que este tipo de análisis constituye una base necesaria para elaborar sistemas de transcripción automática de música y reconocimiento de acordes.

3.2.3. Representación musical: notas y acordes

A lo largo de este trabajo se usa el cifrado americano, también llamado cifrado literal, que clasifica las notas de la A a la G comenzando por la nota La. La razón de esta elección es principalmente operativa: el sistema ofrece una nomenclatura uniforme que simplifica tanto la escritura de acordes como su tratamiento sistemático. El cifrado funciona mediante sufijos y extensiones estandarizadas. La ausencia de sufijo indica un acorde mayor (C); el sufijo "m" señala un acorde menor (Cm); "7" corresponde a un acorde dominante (C7). Desde ahí, pueden representarse estructuras más complejas: extensiones como novenas, oncenas o treceñas (C9, C11, C13), alteraciones (C7#5, C7b9) y adiciones (Cadd9). Esta codificación compacta permite leer de un vistazo la sonoridad y la función armónica de cada acorde, lo que resulta especialmente conveniente en tareas de análisis y procesamiento automático de información musical.

3.2.4. Extracción de características

Para facilitar el análisis automático de señales de audio, es necesario extraer características relevantes. Entre las más utilizadas se encuentran:

- Espectrogramas
- Transformada Constant-Q (CQT)
- Características cromáticas (chroma features)

El proceso de extraer las características es una etapa fundamental necesaria para el procesamiento de audio, esto se fundamenta en el hecho de transformar una señal en su etapa cruda y volverla a una representación numérica, que es aquí donde es aplicable los modelos de machine learning. En el concepto de música se convierte en una etapa crucial para extraer información del tipo armónico y de los tiempos de una señal [1, 2].

Las señales de audio en si representan una alta variabilidad y de igual forma alta complejidad, por lo que es necesario representar patrones significativos en el dominio tiempo-frecuencia. Aquí es donde los espectrogramas se pueden utilizar como representación base, esto debido a que permiten analizar la evolución temporal de las frecuencias presentes en una señal [22].

El espectrograma se obtiene a partir de la Transformada de Fourier de tiempo corto (Short-Time Fourier Transform, STFT), la cual se define como:

$$X(n, k) = \sum_{m=-\infty}^{\infty} x[m] w[n - m] e^{-j2\pi km/N} \quad (3.1)$$

donde $x[m]$ es la señal de audio, $w[n]$ es una ventana de análisis, n representa el índice temporal y k el índice de frecuencia. Esta formula nos permite representar los segmentos locales de la señal y de igual forma analizarlos, tomando información relevante tanto del aspecto temporal como frecuencial.

La ventaja de tomar información a partir del espectrograma, es la posibilidad de derivar otras características más específicas para el análisis musical. Una de las más relevantes es la Transformada de Q constante (Constant-Q Transform, CQT), la cual ofrece una resolución logarítmica en datos de frecuencia, permitiendo ya lo que es una alineación mucho más apta a la percepción musical humana [23]. La CQT se define como:

$$X_{CQT}(k) = \sum_{n=0}^{N_k-1} x[n] a_k^*[n] \quad (3.2)$$

donde $a_k[n]$ corresponde a los filtros de frecuencia centrados en cada banda k .

Por otro lado, otra característica muy útil y muy usada en un análisis musical es el *chroma*, por la cual se agrupa la energía de las frecuencias en 12 clases correspondientes a las notas

musicales de la escala cromática. Al utilizar este tipo de representación se vuelve muy útil al momento de identificar acordes, ya que captura la estructura armónica independientemente de la octava y toma como tal la base [24].

El vector cromático se puede expresar como:

$$c(p) = \sum_{k \in \mathcal{K}_p} |X(k)| \quad (3.3)$$

donde $\mathcal{K}_p$ representa el conjunto de frecuencias asociadas a la clase tonal p .

Tomando en conjunto, lo que son estas representaciones permiten reducir la dimensionalidad de una señal de audio y abstraer características relevantes en uso y volverlas una clasificación, permitiendo una entrada de datos que facilite el entrenamiento de modelos de aprendizaje automático, ya para una detección e identificación de acordes musicales.

3.2.5. Aprendizaje automático aplicado al audio

Una herramienta clave para la elaboración del sistema es entender el uso de un aprendizaje automático (Machine Learning), esta consiste en una rama de la inteligencia artificial que permite a los sistemas computacionales aprender patrones a partir de datos y mejorar constantemente su desempeño sin ser programados en cada mejora como tal. Para este enfoque, se busca que un modelo se entrene utilizando datos de entrada con sus respectivas etiquetas, permitiendo posteriormente el realizar predicciones sobre nuevos datos [2].

Ya para el contexto del procesamiento de audio, el aprendizaje automático se utiliza en si para analizar y reconocer patrones presentes en señales sonoras, como lo son la voz, la música o sonidos ambientales. Sin embargo, trabajar con audio presenta desafíos que según la escala pueden llegar a ser muy complejos, esto se debe a que las señales no son directamente interpretables como datos estructurados por lo que es necesario que antes sean transformadas en representaciones numéricas adecuadas para el análisis [22].

Parte III

Desarrollo

Capítulo 4

Diseño e implementación

4.1. Alcance

El alcance de este trabajo se centra en el desarrollo de un sistema automático para la identificación de acordes a partir de grabaciones de audio de guitarra acústica. Este sistema se diseñará específicamente para reconocer acordes en el contexto de la música popular occidental, utilizando el cifrado americano como formato de representación simbólica. El enfoque se limitará a acordes comunes y sus variaciones más frecuentes, sin abordar acordes extremadamente complejos o poco convencionales. Además, el sistema se evaluará principalmente en términos de precisión de identificación de acordes, sin considerar aspectos relacionados con la interpretación musical o la calidad sonora de las grabaciones. El alcance también incluye la implementación de modelos de aprendizaje automático y la comparación de diferentes representaciones acústicas, pero no se extenderá a la creación de una aplicación de usuario final o a la integración con plataformas de música digital.

4.1.1. Objetivo general del alcance

Crear una solución de software que permita la identificación de acordes de guitarra clásica a partir de pistas de audio, con una precisión $\geq 85\%$, representando los acordes identificados en cifrado americano, y evaluando su desempeño mediante métricas de exactitud y robustez frente a variaciones de ejecución y ruido.

4.1.2. Delimitación funcional

- **Ingesta de audio:** El sistema estará diseñado para el procesamiento de pistas de audio de guitarra acústica con encordado de nylon, con afinación estándar a $440Hz$ en formatos *.wav*, *.flac* y *.mp3* con una tasa de muestreo mínima de $44,1kHz$ y una profundidad de bits de al menos 16 bits. No se tiene contemplado el procesamiento de audio en tiempo real, ni la transcripción de otro tipo de instrumentos o variaciones de guitarra.

- **Pre-procesamiento espectral:** El sistema realizará el pre-procesamiento de las pistas de audio desde la extracción de características acústicas, incluyendo la generación de espectrogramas, transformada Constant-Q (CQT), características cromáticas (chroma features) y energía de armónicos con una normalización y segmentación en frames de 0,5s con un solapamiento del 50 %. No se incluirán técnicas avanzadas de separación de fuentes o reducción de ruido más allá de filtros básicos.
- **Modelo de aprendizaje automático:** El sistema implementará y entrenará tres arquitecturas de aprendizaje automático, CNN-2D, CNN+RNN y Transformer, utilizando un conjunto de datos etiquetado de acordes de guitarra acústica. La optimización de hiperparámetros se realizará mediante búsqueda bayesiana, pero no se explorarán técnicas de meta-aprendizaje o aprendizaje profundo más avanzadas. De igual forma la comparación entre los modelos se realizará de forma interna, de tal forma que el sistema determina de forma autónoma el mejor modelo, sin embargo no se contempla una comparación con modelos de última generación o con sistemas comerciales existentes.
- **Post-procesado de resultados:** El sistema realizará la conversión del vector de probabilidades a la notación de cifrado americano, aplicando umbrales de decisión para la clasificación de acordes, así como también el agrupamiento de acordes idénticos para evitar repeticiones innecesarias. No se incluirá el análisis de progresiones armónicas ni la generación de partituras complejas.

4.2. Limitaciones

A pesar de los avances en el campo de la transcripción automática de música, existen varias limitaciones que deben ser consideradas al desarrollar y evaluar sistemas de detección de acordes. En primer lugar, la calidad y diversidad del conjunto de datos utilizado para entrenar los modelos pueden afectar significativamente su rendimiento. Si el conjunto de datos no incluye una amplia variedad de estilos musicales, técnicas de ejecución y condiciones de grabación, el modelo puede tener dificultades para generalizar a situaciones del mundo real. Además, la presencia de ruido de fondo, variaciones en la afinación y técnicas de ejecución no convencionales pueden degradar el rendimiento del sistema, lo que limita su aplicabilidad en entornos no controlados [1].

Otra limitación importante es la capacidad de los modelos para manejar la polifonía compleja de la guitarra acústica, donde múltiples notas se superponen y generan espectros armónicos complejos. Finalmente, aunque se pueden lograr altos niveles de precisión en la detección de acordes, es importante reconocer que ningún sistema de transcripción automática puede igualar completamente la capacidad de un músico profesional para interpretar y comprender la música, lo que implica que siempre habrá un margen de error y limitaciones en la interpretación de los resultados [2].

4.3. Plan de trabajo

Para el desarrollo de este trabajo de investigación se propone el siguiente plan de trabajo, dividido en etapas con sus respectivas actividades y cronograma, el cual se desarrollará durante un período de dos semestres académicos y se detallará en su respectiva sección más adelante:

4.3.1. Revisión documental

Durante esta etapa, se realizará la búsqueda y recopilación de datasets de audio de guitarra acústica, con la mayor cantidad de información adicional posible como notaciones o archivos MIDI para mejorar la calidad de las etiquetas y garantizar la mejor calidad de los datos posible.

4.3.2. Implementación del modelo

En esta fase, se llevará a cabo la implementación de los modelos de aprendizaje automático seleccionados para la detección de acordes, empleando prácticas de codificación eficientes y asegurando la reproducibilidad de los resultados. Se documentará el proceso de implementación y se prepararán los scripts necesarios para el entrenamiento y evaluación de los modelos.

4.3.3. Preprocesamiento de datos

En esta fase, se llevará a cabo la limpieza y normalización de los datos de los datasets elegidos para el proyecto, así como la extracción de características relevantes para la detección de acordes. Se evaluarán diferentes técnicas de preprocesamiento para mejorar la calidad de las representaciones de audio.

4.3.4. Entrenamiento del modelo

En esta etapa, se implementarán y entrenarán diferentes modelos de aprendizaje automático para la detección de acordes, utilizando las características extraídas en la fase anterior. Se optimizarán los hiperparámetros de los modelos para mejorar su rendimiento.

4.3.5. Comparación de modelos

Una vez entrenados los modelos, se realizará una comparación exhaustiva de su desempeño utilizando métricas de evaluación como exact-match accuracy, top-3 accuracy y macro-F1. Se analizarán los resultados para determinar cuál modelo ofrece el mejor rendimiento en la tarea de detección de acordes.

4.3.6. Pruebas

Finalmente, se evaluará la robustez del mejor modelo frente a variaciones de afinación, técnicas de ejecución y presencia de ruido de fondo, comparando los resultados obtenidos con una revisión manual bajo los criterios de teoría musical. Se documentarán los resultados obtenidos y se discutirán las limitaciones del sistema propuesto, así como posibles mejoras y aplicaciones futuras en el ámbito de la transcripción musical automática y el análisis de audio.

4.4. Cronograma

El cronograma propuesto para el desarrollo de la investigación está distribuido en un período de ocho (8) meses a partir de la aprobación del anteproyecto. El Cuadro 4.1 ilustra la distribución temporal de las fases del plan de trabajo.

Cuadro 4.1: Cronograma de actividades del proyecto

Actividad	M1	M2	M3	M4	M5	M6	M7	M8
Revisión documental	•	•						
Preprocesamiento de datos		•	•					
Implementación del modelo				•	•			
Entrenamiento del modelo					•	•	•	
Comparación de modelos							•	
Pruebas								•

Al finalizar cada una de estas actividades, se espera cumplir con los siguientes entregables principales:

- **Mes 1 - 2 — Revisión documental:** Datasets seleccionados y documentados, junto con la revisión bibliográfica consolidada.
- **Mes 2 - 3 — Preprocesamiento de datos:** Pipeline de código funcional con la extracción de características espectrales validadas.
- **Mes 4 - 5 — Implementación del modelo:** Arquitecturas base implementadas y listas para su entrenamiento.
- **Mes 5 - 7 — Entrenamiento del modelo:** Modelos entrenados con hiperparámetros optimizados y resultados preliminares registrados.
- **Mes 7 — Comparación de modelos:** Reporte de desempeño comparativo con las métricas establecidas (exact-match accuracy, top-3 accuracy, macro-F1).
- **Mes 8 — Pruebas:** Validación de robustez finalizada y entrega del documento de tesis.

Bibliografía

- [1] E. Benetos, S. Dixon, Z. Duan, and S. Ewert, “Automatic music transcription: An overview,” *IEEE Signal Processing Magazine*, vol. 36, no. 1, pp. 20–30, 2019.
- [2] F. Jamshidi and G. Anbarjafari, “Machine learning techniques in automatic music transcription: A systematic survey,” *Artificial Intelligence Review*, 2024, also available as arXiv:2406.15249; verify final journal DOI upon Artificial Intelligence Review publication.
- [3] E. Benetos, S. Dixon, Z. Duan, and S. Ewert, “Automatic music transcription: An overview,” *IEEE Signal Processing Magazine*, vol. 36, no. 1, pp. 20–30, 2018.
- [4] A. Klapuri, “Automatic transcription of recorded music,” *Acta Acustica united with Acustica*, vol. 92, no. 2, pp. 306–318, 2006.
- [5] “Data representations for audio-to-score monophonic music transcription,” *Expert Systems with Applications*, vol. 152, p. 113769, 2020.
- [6] “Design and implementation of piano audio automatic music transcription algorithm based on convolutional neural network,” *EURASIP Journal on Audio, Speech, and Music Processing*, 2025.
- [7] “Recognition of piano playing notes by a music transcription algorithm,” *Journal of Advanced Computational Intelligence and Intelligent Informatics*, 2025.
- [8] “A holistic approach to polyphonic music transcription with neural networks,” *arXiv preprint arXiv:1910.12086*, 2019.
- [9] “Non-local musical statistics as guides for audio-to-score piano transcription,” *Information Sciences*, vol. 560, pp. 36–52, 2021.
- [10] “Automatic transcription of organ tablature music notation with deep neural networks,” *Transactions of the International Society for Music Information Retrieval*, 2022.
- [11] “End-to-end automatic music transcription of polyphonic qanun and oud music using deep neural networks,” *Eskişehir Technical University Journal of Science and Technology A*, 2024.
- [12] “Automatic musical transcription applying fine-tuning by composer in neural networks for the musicnet database,” *ResearchGate publication*, 2022.

- [13] “Context-aware audio-to-score alignment using recurrent neural networks,” *Information Sciences*, 2021.
- [14] “Machine learning techniques in automatic music transcription: A systematic survey,” *Artificial Intelligence Review*, 2024.
- [15] “Automatic music transcription using convolutional neural networks and constant-q transform,” *arXiv*, 2025.
- [16] “Note-level singing melody transcription for time-aligned musical score generation,” *arXiv*, 2025.
- [17] “Audio-to-score alignment of piano music using rnn-based automatic music transcription,” 2018.
- [18] “Automatic piano sheet music transcription with machine learning,” *Journal of Computer Science*, 2021.
- [19] “Processing piano audio: Automatic transcription model for sound signals,” *Journal of Measurements in Engineering*, 2024.
- [20] “Humanities and engineering perspectives on music transcription,” *Digital Scholarship in the Humanities*, 2022.
- [21] “Automatic music transcription: Challenges and future research,” *Journal of Intelligent Information Systems*, 2014.
- [22] M. A. Román, A. Pertusa, and J. Calvo-Zaragoza, “Data representations for audio-to-score monophonic music transcription,” *Expert Systems with Applications*, vol. 152, p. 113769, 2020.
- [23] Y. K. Telila, T. Cucinotta, and D. Bacciu, “Automatic music transcription using convolutional neural networks and constant-q transform,” *arXiv preprint*, vol. abs/2505.04451, 2025.
- [24] E. Benetos, S. Dixon, D. Giannoulis, H. Kirchhoff, and A. Klapuri, “Automatic music transcription: Challenges and future directions,” *Journal of Intelligent Information Systems*, vol. 41, no. 3, pp. 407–434, 2013.