

Detección Automática de Acordes de Guitarra Acústica

Avance — Entrenamiento CNN 2-D sobre GuitarSet

Transcripción Automática de Música (AMT) · Music Information Retrieval (MIR)

CNN
2-D
GuitarSet

► Resumen del Proyecto

La **Transcripción Automática de Música (AMT)** busca convertir señales de audio en representaciones simbólicas como acordes. Este trabajo desarrolla un sistema de clasificación de acordes de guitarra acústica usando **aprendizaje profundo** sobre características espectrales extraídas con STFT, CQT y chroma features.

Desafío: Los instrumentos polifónicos generan superposiciones armónicas complejas que dificultan la separación y clasificación de acordes.

• Objetivo

Desarrollar un sistema automático que identifique acordes de guitarra acústica con una **precisión exacta mínima del 85 %**, representando los resultados en cifrado americano.

Métricas de evaluación:


- Exact-match accuracy
- Top-3 accuracy
- Macro-F1

▢ Dataset — GuitarSet

Instrumento Guitarra acústica (nyloñ)
Afinación Estándar 440 Hz
Formatos .wav, .flac, .mp3
Muestreo ≥ 44.1 kHz / 16 bit
Frames 0.5s, solapamiento 50 %
Validación 5-fold cross-validation

★ Arquitectura CNN 2-D

Audio .wav / .flac / .mp3



Optimización: Búsqueda bayesiana de hiperparámetros (lr, batch size, número de capas)

Entrenamiento: PyTorch + librosa · 50 épocas · Adam · Cross-entropy loss



55.12 %
Acc. entrenamiento
(época 50)

45.64 %
Mejor acc. prueba
(época 31)

1.4777
Loss final
Cross-entropy (ép. 50)

50
Épocas totales
≈39 s / ép. (inicio)

~ Curvas de Entrenamiento — CNN 2-D (50 épocas)



✓ Análisis de Resultados

- La **pérdida de entrenamiento** disminuye consistentemente de 2.677 a 1.478 a lo largo de 50 épocas, indicando convergencia sostenida.
- La **exactitud de entrenamiento** sube de 21.5 % a 55.1 %, reflejando una capacidad de ajuste progresiva sobre GuitarSet.
- La **exactitud de prueba** se estabiliza entre 42 %–45 %, alcanzando su pico en **45.64 % en la época 31**, con variabilidad posterior.
- La brecha entre train acc (55 %) y test acc (43 %) sugiere **sobreajuste moderado**, indicando necesidad de mayor regularización o datos.
- El desempeño actual está **por debajo del 85 %** objetivo, lo que motiva la exploración de CNN+RNN y Transformer.

⇒ Próximos Pasos

Arquitecturas pendientes: CNN+RNN (LSTM) para capturar dependencias temporales entre acordes; Transformer con atención multi-cabeza sobre espectrogramas.

Mejoras al CNN-2D: Aumentación de datos (pitch shifting, time stretching), ajuste de dropout, búsqueda bayesiana de hiperparámetros.

Evaluación de robustez: Pruebas con variaciones de afinación, técnicas de ejecución (dedos vs púa) y ruido de fondo. Análisis por factor.

Meta final: Comparación cruzada de los tres modelos; publicación y liberación de código bajo licencia MIT en GitHub.

Herramientas: Python · PyTorch · librosa · GuitarSet
STFT · CQT · Chroma features · Energía armónicos

Área: Music Information Retrieval
Transcripción Automática de Música (AMT)

[GitHub] Código bajo licencia MIT
Avance — CNN 2-D · 50 épocas